


Thu thập dữ liệu


- Nguồn kiến thức:
 - + Các trang thông tin về lịch sử, đào tạo, ... trên các website của VNU, UET bằng Tiếng Việt.
 - + Các trang wikipedia bằng Tiếng Anh về các tay vợt quần vợt: Rafael Nadal, Novak Djokovic, Roger Federer.
 - + Các trang wikipedia bằng Tiếng Tây Ban Nha về các cầu thủ bóng đá: Cristiano Ronaldo, Lionel Messi.
 - Cách thu thập:
 - + Với nguồn kiến thức về VNU, UET: Sử dụng beautifulsoup4 để xử lý file HTML gán ở mỗi trang thông tin.
 - + Với nguồn kiến thức về các tay vợt, cầu thủ bóng đá: Tải file PDF xuống.
- => Tất cả đều được lưu vào folder "raw_data" (dữ liệu về VNU, UET lưu dưới dạng file .txt; dữ liệu về các vận động viên lưu dưới dạng .pdf).



Tạo dataset

Bộ dataset bao gồm 270 câu hỏi với tập huấn luyện và 30 câu hỏi với tập kiểm tra (90 câu train, 10 câu test với mỗi nguồn kiến thức ứng với một ngôn ngữ khác nhau).

Được lưu dưới dạng như sau:



Mô hình Chatbot

- Từ các file PDF và .txt, tạo thành các mảng chuỗi ký tự, với mỗi đoạn trong từng file là một phần tử.
- Mô hình truy xuất: Sử dụng mô hình [deepset/xlm-roberta-base-squad2](#) với mục đích có thể hỗ trợ nhiều ngôn ngữ khác nhau (trong đó có cả Tiếng Anh, Tiếng Việt và Tiếng Tây Ban Nha).
=> Truy xuất tài liệu dựa trên những keyword của câu hỏi, từ đó đưa ra câu trả lời.
- Mô hình prompt: Sử dụng mô hình [Qwen/Qwen1.5-1.8B-Chat](#) kết hợp với câu lệnh Prompt đầu vào để sinh văn bản.
- Mô hình huấn luyện:
 - + Xử lý dữ liệu: Khớp nối mỗi câu hỏi trong bộ file train/test với câu trả lời tương ứng và với những tài liệu có keyword trùng với câu hỏi và đưa thông tin giống với câu trả lời, tạo thành những file .json.
 - + Từ những file .json trên, tạo ra những bộ dataset phục vụ huấn luyện và đánh giá.

- + Mô hình được huấn luyện là mô hình [openai-community/gpt2](https://openai-community.github.io/gpt2/), với các tham số huấn luyện như sau:

```
training_args = SFTConfig(
    output_dir="./results_llm_sft",
    per_device_train_batch_size=2,
    gradient_accumulation_steps=4,
    learning_rate=2e-4,
    logging_steps=1,
    num_train_epochs=3,
    save_strategy="epoch",
    eval_strategy="epoch",
    per_device_eval_batch_size=2,
    load_best_model_at_end=True,
    metric_for_best_model="loss",
    greater_is_better=False,

    # ✨ DI CHUYỂN 2 THAM SỐ GÂY LỖI VÀO ĐÂY ✨
    dataset_text_field="text", # Chỉ định cột dữ liệu văn bản ở đây
    max_length=1024 # Chỉ định độ dài chuỗi tối đa ở đây
)
```

- + Mô hình được fine-tune trên bộ dataset đã có sẵn và sau khi đánh giá sẽ giữ lại mô hình có loss thấp nhất.

[42/42 02:00, Epoch 3/3]

Epoch	Training Loss	Validation Loss	Rouge1	RougeL	Exact Match	Entropy	Num Tokens	Mean Token Accuracy
1	2.697431	1.410258	0.734600	0.618500	0.000000	1.428795	72766.000000	0.685389
2	1.656047	1.196169	0.728000	0.634200	0.000000	1.173059	145532.000000	0.718648
3	1.238099	1.137705	0.740300	0.644900	0.000000	1.114787	218298.000000	0.731429

- + Mô hình tốt nhất được lưu lại để phục vụ công tác test inference.
- + Việc test inference được thực hiện với các câu hỏi là các câu hỏi trong tập data/test/questions.txt (bộ câu hỏi test) và được lưu vào file test_predictions.json.

TOÀN BỘ QUÁ TRÌNH TRÊN ĐƯỢC THỰC HIỆN TRÊN KAGGLE (file source code: assignment-2-rag-chatbot.ipynb)